

Universidad Nacional de Loja



Nombre:

Juan Alberto Calopino Martínez

Fecha:

6 de mayo, 2026

Curso:

Ingeniería en Computación - Cuarto Ciclo

Docente:

Luis Chamba

Materia:

Sistemas Operativos

Periodo:

2026

Declaración de uso de IA Generativa

Yo, **Juan Alberto Calopino Martinez**, en calidad de autor, declaro de manera transparente y responsable el uso de herramientas de Inteligencia Artificial Generativa (IAG) durante el desarrollo del presente trabajo, en conformidad con los principios de integridad académica, ética investigativa y buenas prácticas en el uso de tecnologías emergentes.

1. Alcance del uso de IA generativa

El uso de herramientas de IAG se ha limitado a funciones de apoyo, sin sustituir el juicio crítico ni la autoría intelectual del autor. En particular, se han utilizado para:

- Mejora de redacción y estilo académico.
- Generación de ideas preliminares.
- Apoyo en la estructuración del documento.
- Asistencia en traducción técnica.

2. Clasificación del uso según GAIDeT

De acuerdo con la taxonomía GAIDeT, el uso de IA generativa en este trabajo se clasifica en:

- **Nivel 1 – Asistencia Lingüística:** Corrección gramatical y mejora de claridad.
- **Nivel 2 – Apoyo en Ideación:** Generación de ideas y esquemas conceptuales.
- **Nivel 3 – Asistencia Técnica:** Apoyo en generación de código y explicaciones técnicas.

No se ha utilizado IA generativa para la generación autónoma de resultados ni para sustituir el análisis crítico del autor.

3. Validación y responsabilidad

Todo contenido asistido por IA ha sido revisado, validado y adaptado por el autor, quien asume la responsabilidad total sobre la calidad, veracidad y originalidad del trabajo.

4. Herramientas utilizadas

Se emplearon modelos de lenguaje (LLMs) y herramientas de asistencia técnica para redacción, estructuración y apoyo conceptual.

5. Consideraciones éticas

El uso de IA se realizó respetando principios de honestidad académica, normativas institucionales de la Universidad Nacional de Loja y buenas prácticas internacionales.

6. Declaración final

Declaro que el uso de IA generativa ha sido ético, transparente y complementario, sin comprometer la autoría ni la integridad académica del presente trabajo.

Loja, Ecuador, 06/05/2026

Juan Alberto Calopino Martinez

Autor

1. Matriz de extracción bibliográfica

# Referencia (IEEE)	Año	Base	Técnica IA	Problema abordado	Objetivo	Metodología	Resultados principales (Ventajas RF)	Limitaciones
[1] A. F. Castillo y S. A. Claro, “Evaluación de preprocesamiento y clasificación automática en imágenes de fisuras en concreto,” UTS, 2025.	2025	UTS	Random Forest vs. Decision Tree	Clasificación automatizada de grietas estructurales en concreto.	Comparar la precisión bajo filtros de preprocesamiento digital.	Extracción morfológica en imágenes y entrenamiento parametrizado.	RF neutralizó por completo el sobreajuste (overfitting) que afectaba al árbol individual, logrando alta estabilidad frente a ruidos visuales.	Alta dependencia del algoritmo de segmentación inicial.
[2] F. G. Arage, T. G. Abate, y T. K. Tsegaw, “Predicting cholesterol abnormalities using machine learning,” Discover AI, vol. 6, 2026.	2026	Springer	Random Forest, DT, AdaBoost	Clasificación diagnóstica de anomalías lipídicas severas.	Determinar la capacidad predictiva frente a registros médicos.	Imputación por MICE, optimización RFE y validación cruzada.	RF demostró una superioridad crítica en sensibilidad (Recall 96.97%) y AUC (96.17%), superando al DT individual (AUC 86.90%).	La interpretabilidad directa se vuelve compleja (caja negra).
[3] M. B. Bertini et al., “Forecasting corporate bankruptcy using modern machine learning,” J. Account. Org. Change, 2025.	2025	Emerald	Random Forest, Gradient Boosting, DT	Riesgo de quiebra corporativa bajo desbalance extremo de clases.	Superar la rigidez de los modelos tradicionales de scoring.	Panel masivo (1.8M registros), balanceo SMOTE y validación out-of-time.	La agregación aleatoria de variables mitiga sesgos por desbalance, logrando AUC de 0.99 donde los DT clásicos colapsaron.	Demanda alta asignación de memoria para almacenar los árboles.
[4] X. Ya, X. Y. Yan, y Z. Zhou, “Dementia Prediction Based on RF Feature Selection and GBDT,” Proc. Intl. Conf. ACM, 2026.	2026	ACM	Random Forest y GBDT	Diagnóstico de demencia clínica con alta dimensionalidad.	Diseñar un marco híbrido que optimice la exactitud diagnóstica.	RF como selector embebido de variables por impureza de Gini.	RF discrimina y extrae de forma óptima patrones cruzados, logrando 96% de precisión y superando la baja tolerancia al ruido del DT.	Costo computacional elevado en el ajuste de hiperparámetros.
[5] M. Sheraz y M. Talha, “Explainable extreme gradient boosting tree prediction of columns,” Sci. Rep., vol. 16, 2026.	2026	Nature	Random Forest, XGBoost	Capacidad de carga estructural en columnas de hormigón.	Desarrollar modelos de alta precisión y explicar variables con SHAP.	Configuración paramétrica en WEKA y mapeo distributivo SHAP.	RF disminuye significativamente el error de varianza extrema en comparación con un solo DT mediante el promediado democrático.	Requiere un entorno iterativo complejo de prueba y error.
[6] M. S. Wang y X. H. Liu, “Predictive capability and feature tracing in multi-depth systems,” Discover Computing, 2026.	2026	Springer	Random Forest, Extra Trees	Fallas críticas en tuberías industriales de gas con sensores masivos.	Minimizar la varianza estructural mediante subconjuntos de variables.	Bosques con 200 estimadores y estrategia de división por raíz cuadrada.	La votación de árboles descorrelacionados estabilizó las fronteras de decisión (R2: 0.906), logrando una generalización inaccesible para DT.	La profundidad máxima debe acotarse para evitar ruidos locales.
[7] Ratih et al., “Performance Evaluation of Random Forest for Detecting Anomalies in Server Logs,” Sinkron, vol. 10, 2026.	2026	Sinkron	Random Forest, Isolation Forest	Ataques cibernéticos dinámicos en registros de servidores web.	Clasificar accesos legítimos de maliciosos en tiempo real.	Extracción de logs Apache y entrenamiento de árboles descorrelacionados.	La inyección dual de aleatoriedad (bagging + variables) capturó firmas mutables de ataques que los DT ignoran por su rigidez geométrica.	Demanda actualización continua del dataset ante ataques día cero.
[8] Y. K. Saheed et al., “Ensemble learning for	2025	Elsevier	Random Forest, Algoritmos	Falsificación e inyección de datos	Minimizar pérdidas de clasificación y	Validación cruzada estratificada K-fold y	RF operó eficientemente sobre series temporales ruidosas,	Elevada complejidad en arquitecturas

anomaly detection in IoT via genetic algorithm,” Results in Eng., 2025.			Genéticos	maliciosos en sensores IIoT.	optimizar hiperparámetros.	rebalanceo interno SMOTE.	reduciendo falsos positivos frente a las divisiones secuenciales fijas del DT.	Edge Computing limitadas.
[9] L. Breiman, “Random Forests,” Machine Learning, vol. 45, no. 1, pp. 5-32, 2001 (Referencia Base).	2001	Springer	Random Forest (Teoría General)	Limitaciones de varianza e inestabilidad en clasificadores base.	Introducir formalmente el ensamble por agregación e interpolación.	Demostración matemática de convergencia del margen y bagging.	Prueba que el error de generalización tiene un límite superior y que RF no sufre de sobreajuste al añadir más árboles, superando al DT.	Pérdida de la interpretabilidad directa del árbol simple.
[10] J. Aparicio, V. Charles, y M. D. Guillen, “Estimating confidence intervals via random forest,” Omega, vol. 143, 2026.	2026	Scopus	Random Forest Efficiency	Sesgo y sobreajuste en la estimación de scores de eficiencia.	Extender RF para corregir sesgos no paramétricos.	Combinación de bootstrapped DEA con remuestreo probabilístico de RF.	RF suavizó las fronteras de producción disminuyendo la varianza del estimador en muestras pequeñas frente a la rigidez de un DT.	Requiere un número elevado de réplicas para intervalos estables.
[11] T. Rashid y M. M. Mokji, “Low-resolution image classification of cracked concrete surface using DT,” Springer, 2022.	2022	Scopus	Decision Tree, Random Forest	Detección de grietas superficiales con imágenes de baja resolución.	Evaluar clasificadores base frente a restricciones de píxeles.	Extracción de características texturales mediante matrices de co-ocurrencia.	Se demostró que ante la reducción de resolución, el RF retiene un 14% más de precisión que DT debido al remuestreo de características.	Mayor tiempo de ejecución en la etapa de inferencia.
[12] M. Wang et al., “Research on Pavement Crack Detection Based on Random Structure Forest,” Automation, 2024.	2024	IEEE	Random Structure Forest	Ruido por sombras y texturas complejas en pavimentos viales.	Aislar grietas reales del ruido ambiental de la carretera.	Clasificación por densidad espacial combinada con estructuras de bosque.	Los subconjuntos aleatorios de RF impiden que las variables de sombra dominen el nodo raíz, superando el error sistemático del DT.	Complejo de implementar en hardware embebido de inspección.
[13] J. Zhu y J. Song, “An intelligent classification model for defects on cement concrete bridges,” Appl. Sci., 2020.	2020	MDPI	Random Forest Classifier	Múltiples clases de defectos (grietas, eflorescencias, descascaramiento).	Clasificación multiclase precisa en puentes de hormigón.	Segmentación de imágenes mediante descriptores locales y bosque.	RF maneja relaciones no lineales complejas multiclase con mayor robustez, evitando la degradación del gradiente del DT.	Sensible a hiperparámetros mal calibrados (min_samples_leaf).
[14] H. Zoubir et al., “Concrete bridge crack image classification using histograms of oriented gradients,” Rguig, 2022.	2022	IEEE	HOG + Random Forest / DT	Alta dimensionalidad producida por los vectores de características HOG.	Optimizar el clasificador para vectores densos de gradientes.	Extracción de HOG y entrenamiento comparativo de clasificadores.	RF gestiona de forma nativa cientos de descriptores por nodo sin requerir reducción previa de dimensiones, superando el colapso del DT.	Elevado consumo de memoria RAM durante el entrenamiento masivo.
[15] V. J. España, J. Aparicio, y X. Barber, “Estimating production functions through additive models,” Eur. J. Oper. Res., 2024.	2024	ScienceDirect	Tree-based Additive Models	Modelado de funciones de producción altamente no lineales.	Superar las limitaciones funcionales de los árboles estándar.	Splines de regresión acoplados a estructuras de división binaria.	Demuestra que el ensamble tipo bosque reduce el error cuadrático medio a la mitad frente a la estructura tosca de un solo árbol.	Dificultad de interpretación macroeconómica directa.
[16] T. Chen y C. Guestrin, “XGBoost: A Scalable Tree Boosting System,” ACM KDD, 2016 (Referencia de Validación).	2016	ACM	XGBoost, Random Forest, DT	Escalabilidad y velocidad en aprendizaje basado en árboles.	Presentar optimizaciones de división dispersa y regularización.	Procesamiento paralelo, algoritmos de división aproximada y bosques.	Se valida que el promediado paralelo (RF) y secuencial (Boosting) superan sistemáticamente la alta varianza y fragilidad del DT.	Requiere un control estricto de la tasa de aprendizaje.

[17] G. Seeja et al., “Visual fault detection in photovoltaic modules using decision tree algorithms,” Energy Sources, 2021.	2021	Taylor&Francis	DT, RF, Deep Features	Fallas visuales sutiles en paneles solares (puntos calientes).	Clasificar defectos a partir de mapas de características profundas.	Extracción de capas CNN combinadas con clasificadores de árboles.	RF maneja de forma eficiente correlaciones espaciales redundantes, manteniendo una tasa de falsos positivos inferior a la de un DT.	La calibración del número óptimo de estimadores toma tiempo.
[18] S. N. Venkatesh y V. Sugumaran, “Combined approach of CNN and ML for visual fault classification,” J. Risk Rel., 2022.	2022	Sage	CNN + Random Forest	Garantizar la seguridad operativa en plantas fotovoltaicas.	Diseñar un flujo automatizado de monitorización de riesgos.	Fusión de vectores densos ResNet y clasificación binaria/multiclase.	El bosque aleatorio previene el sobreajuste en el vector final de características profundas, superando con creces la exactitud del DT.	No es apto para entornos de microcontroladores ultra-ligeros.
[19] M. S. Mahmud y X. Fu, “Unsupervised Classification of High-dimension Low-sample Data,” Proc. ICARM, 2019.	2019	IEEE	VAE + Random Forest	Sobreajuste crítico en datos con pocas muestras y miles de variables.	Reducir dimensionalidad manteniendo la separabilidad de clases.	Codificación variacional (VAE) seguida de clasificación supervisada.	RF demostró que al recibir variables latentes probabilísticas, su robustez supera el sesgo de partición determinista del DT.	Dependencia del espacio latente generado por el autoencoder.
[20] Q. Xiong et al., “Vibration Recognition Based on Feature Extraction by Deep Autoencoder,” Proc. FAIML, 2023.	2023	ACM	Deep Autoencoder + RF / DT	Señales de vibración industrial ruidosas y no estacionarias.	Monitorear la salud estructural de maquinaria rotativa.	Compresión con Autoencoder profundo y clasificación multiclase.	RF es inmune a las fluctuaciones menores de las señales temporales comprimidas gracias al ensamble, superando la inestabilidad del DT.	Requiere una fase pesada de pre-entrenamiento de la red.