

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	Introducción y Fundamentos	1
II	Aprendizaje Estadístico y Modelos de Clasificación	2
1.	Análisis Comparativo y Ventajas de Random Forest Frente a Árboles de Decisión en Problemas de Clasificación.	3
1.1.	Introducción	3
1.2.	Fundamentos Teóricos	3
1.3.	Metodología y Análisis de la Literatura	3
1.4.	Conclusiones	4

Parte I

Introducción y Fundamentos

Parte II

Aprendizaje Estadístico y Modelos de Clasificación

Capítulo 1

Análisis Comparativo y Ventajas de Random Forest Frente a Árboles de Decisión en Problemas de Clasificación.

Autor: Juan Alberto Calopino Martinez (juan.calopino@unl.edu.ec)
Técnica asignada: Random Forest

1.1. Introducción

Este capítulo aborda formalmente el análisis comparativo y las capacidades operativas de los algoritmos de aprendizaje supervisado para dar respuesta a la pregunta de investigación planteada: ¿Qué ventajas ofrece Random Forest frente a árboles de decisión en problemas de clasificación? A través del estudio de aplicaciones críticas como el diagnóstico de demencia, la detección de víctimas en desastres y la inspección de infraestructura civil, se examina cómo la transición de un modelo individual a uno de ensamble optimiza la precisión y la robustez de los sistemas de inteligencia artificial [1], [2].

1.2. Fundamentos Teóricos

El Random Forest (RF) se define como una variante del método de Bagging que integra múltiples árboles de decisión para construir un modelo de ensamble más robusto. A diferencia de un Árbol de Decisión (DT) convencional, que selecciona el atributo óptimo global para cada división, el RF introduce una doble aleatoriedad: el uso de subconjuntos de datos mediante bootstrap y la selección de un subconjunto de atributos en cada nodo

Matemáticamente, si un conjunto de datos posee d atributos, el RF selecciona aleatoriamente un subconjunto k , donde la recomendación técnica general para optimizar la diversidad del modelo es:

$$P(X_1, X_2, \dots, X_n) = \prod_{i=1}^n P(X_i \mid \text{Padres}(X_i)) \quad (1.1)$$

1.3. Metodología y Análisis de la Literatura

A través de la metodología de jerarquización científica y la extracción de datos de artículos indexados en bases de datos de alto impacto [?], se estructuraron las dimensiones de rendimiento técnico explicadas en la Tabla 1.1.

Tabla 1.1: Dimensiones de análisis en redes probabilísticas clínicas.

Parámetro	Ventaja Tecnológica	Restricción
Cómputo	Consumo mínimo de memoria RAM	Complejidad algorítmica NP-Hard
Explicabilidad	Trazabilidad analítica exacta	Dependencia de expertos de dominio

1.4. Conclusiones

Las técnicas analíticas clásicas analizadas en este volumen proveen una base de explicabilidad matemática robusta, la cual es crucial para auditar las soluciones automatizadas modernas en la ingeniería de software actual.

Referencias

- [1] G. Seeja, A. S. Arockia Doss, and V. B. Hency, “A novel approach for disaster victim detection under debris environments using decision tree algorithms with deep learning features,” *IEEE Access*, vol. 11, pp. 53134–53148, 2023.
- [2] X. Ya, Yan, Yajie, and Zhou, “Dementia prediction based on random forest feature selection and gradient boosting decision tree,” in *Proceedings of the 2023 6th International Conference on Artificial Intelligence and Pattern Recognition (AIPR)*, pp. 1–6, 2023.