

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	Introducción y Fundamentos	1
II	Aprendizaje Estadístico y Modelos de Clasificación	2
6.	Análisis Comparativo y Ventajas de Random Forest Frente a Árboles de Decisión en Problemas de Clasificación.	3
6.1.	Introducción	3
6.2.	Fundamentos Teóricos	4
6.2.1.	Criterios de División: Impureza de Gini y Entropía	4
6.2.2.	Geometría de las Fronteras de Decisión Ortogonales	4
6.2.3.	Poda por Complejidad de Costo (Cost-Complexity Pruning)	5
6.2.4.	Inestabilidad Estructural y Análisis de Varianza	5
6.2.5.	Bootstrap Aggregating (Bagging) y Muestreo con Reemplazo	5
6.2.6.	Selección Aleatoria de Subespacios de Características	6
6.2.7.	Teorema de Convergencia de Breiman	6
6.2.8.	Función de Correlación entre Árboles (P)	6
6.2.9.	Estimación Analítica del Error Out-Of-Bag (OOB)	7
6.2.10.	Fundamentos Matemáticos de la Importancia de Variables	7
6.3.	Metodología y Análisis de la Literatura	7
6.3.1.	Metodología de Revisión	7
6.3.2.	Ciencias de la Salud	8
6.3.3.	Riesgo Financiero y Economía	8
6.3.4.	Ingeniería, IoT y Ciberseguridad	8
6.3.5.	Optimización Algorítmica	9
6.3.6.	Mapeo Comparativo Macroscópico de la Literatura	9
6.3.7.	Síntesis de Limitaciones Estructurales Reportadas en la Literatura	10
6.4.	Conclusiones	11

Parte I

Introducción y Fundamentos

Parte II

Aprendizaje Estadístico y Modelos de Clasificación

Capítulo 6

Análisis Comparativo y Ventajas de Random Forest Frente a Árboles de Decisión en Problemas de Clasificación.

Autor: Juan Alberto Calopino Martinez (juan.calopino@unl.edu.ec)
Técnica asignada: Random Forest

6.1. Introducción

La arquitectura de los clasificadores basados en árboles se fundamenta en el particionamiento binario recursivo del espacio de características, una estrategia de inducción orientada a segmentar un conjunto de datos heterogéneo en regiones progresivamente más homogéneas [1, 2]. Este proceso opera bajo una lógica de jerarquía estructural donde las decisiones se ejecutan mediante una secuencia de reglas condicionales aplicadas en nodos internos, convergiendo finalmente en nodos terminales u hojas que representan la etiqueta de clase predicha [3, 4].

Históricamente, el desarrollo de estos modelos se consolidó con la formalización del algoritmo CART (Classification and Regression Trees) por Breiman et al. en 1984, el cual introdujo el empleo del índice de Gini y la minimización del error cuadrático medio como criterios fundamentales para la división de nodos [5, 6]. Simultáneamente, el paradigma inductivo se expandió con las propuestas de Quinlan, notablemente el algoritmo C4.5 (1993), que estandarizó el uso de la entropía y la ganancia de información para el manejo de atributos continuos y el tratamiento de valores ausentes [1, 7].

A pesar de su transparencia interpretativa y eficiencia operativa, los árboles de decisión individuales presentan una deficiencia matemática inmanente: la alta varianza y propensión al sobreajuste (overfitting) [6, 8]. Al ser estimadores no paramétricos de alta capacidad, los árboles tienden a generar fronteras de decisión excesivamente complejas que memorizan el ruido estocástico y las fluctuaciones del conjunto de entrenamiento en lugar de capturar la función de densidad subyacente [9, 10]. Esta sensibilidad estructural implica que perturbaciones mínimas en el dataset original pueden derivar en topologías de árbol inconsistentes, degradando severamente la capacidad de generalización en datos no observados [11, 12].

La inestabilidad ante el ruido visual y textural restringe la fiabilidad de estos modelos base en entornos reales complejos, donde el error de predicción se incrementa debido a la rigidez de una lógica de decisión única [4, 13]. La necesidad metodológica de mitigar estas limitaciones forzó la evolución hacia el Aprendizaje por Ensemble (Ensemble Learning), basado en el principio estadístico de que la agregación de múltiples "aprendices débiles" permite converger hacia un "aprendiz fuerte" siempre que los errores cometidos por los modelos base no estén correla-

cionados [7,9]. La primera respuesta formal fue el Bagging (Bootstrap Aggregating), propuesto por Breiman en 1996, diseñado para reducir la varianza mediante el entrenamiento de múltiples clasificadores sobre subconjuntos de datos generados mediante muestreo con reemplazo [6,14]. No obstante, el Bagging sobre árboles de decisión presentaba una correlación residual elevada si existían características dominantes en el dataset [9].

La optimización definitiva de este paradigma se materializó con la creación de Random Forest (RF) por Leo Breiman en 2001, integrando el concepto de subespacios aleatorios propuesto inicialmente por Ho en 1995 [5]. RF implementa una doble capa de aleatorización: la primera sobre las observaciones (bootstrapping) y la segunda sobre los atributos en cada partición de nodo, forzando la diversidad y desacoplando las predicciones de los árboles individuales [13,15,16].

Esta arquitectura de votación colectiva garantiza la convergencia del error de generalización y dota al modelo de una robustez superior frente a datos ruidosos o desbalanceados, consolidando a Random Forest como la solución evolutiva óptima para problemas de clasificación de alta dimensionalidad en la Inteligencia Artificial Clásica [2].

6.2. Fundamentos Teóricos

6.2.1. Criterios de División: Impureza de Gini y Entropía

La construcción de un Árbol de Decisión (DT) individual se fundamenta en la partición binaria recursiva del espacio de características, donde el objetivo principal es maximizar la homogeneidad de las clases en los nodos resultantes [1,3]. Este proceso de inducción requiere métricas estadísticas de pureza para evaluar la calidad de cada división potencial en los nodos internos [4]. El Índice de Gini es el criterio predominante en algoritmos como CART, midiendo la probabilidad de clasificar erróneamente un elemento elegido al azar si este fuera etiquetado según la distribución de clases en el nodo [2,7]. Matemáticamente, la optimización busca minimizar esta métrica para alcanzar nodos terminales u hojas con una pureza máxima. Alternativamente, el criterio de Ganancia de Información, central en arquitecturas como C4.5, utiliza la Entropía para cuantificar la incertidumbre o el desorden de la información en un conjunto de datos determinado [1,7]. Al realizar una división, se calcula la reducción neta de entropía, lo que permite seleccionar el atributo que mejor segmenta el espacio muestral [7]. Estas funciones de impureza son críticas para la estabilidad del modelo, ya que definen la jerarquía de las reglas condicionales [3].

$$Gini(S) = 1 - \sum_{k=1}^K p_k^2 \quad ; \quad Entropy(S) = - \sum_{i=1}^n p_i \log_2(p_i) \quad (6.1)$$

6.2.2. Geometría de las Fronteras de Decisión Ortogonales

La arquitectura jerárquica de los árboles de decisión impone una restricción geométrica fundamental: la creación de fronteras de decisión ortogonales a los ejes de las características [1]. Cada nodo del árbol ejecuta una partición binaria basada en un único atributo X_j y un umbral s , lo que divide el espacio multidimensional en hiper-rectángulos paralelos a los ejes [3,4]. Esta propiedad facilita la interpretabilidad del modelo mediante reglas condicionales simples, pero limita la capacidad de aproximar fronteras de decisión oblicuas o circulares de manera eficiente con un solo estimador [17]. En entornos de alta dimensionalidad, un solo árbol debe profundizar excesivamente para capturar interacciones no lineales complejas, lo que deriva en una estructura fragmentada y susceptible al ruido [9]. Mientras que el árbol individual segmenta el espacio de forma rígida, Random Forest suaviza estas fronteras mediante la agregación de múltiples perspectivas geométricas, logrando una frontera de decisión mucho más flexible y robusta que

se adapta mejor a la densidad real de los datos sin perder la ventaja del particionamiento recursivo [6, 8].

$$R_1(j, s) = X|X_j \leq s \quad y \quad R_2(j, s) = X|X_j > s \quad (6.2)$$

6.2.3. Poda por Complejidad de Costo (Cost-Complexity Pruning)

Para mitigar la tendencia natural de los árboles de decisión al sobreajuste, se implementan mecanismos de regularización técnica conocidos como poda [6, 17]. La poda por complejidad de costo utiliza un parámetro de penalización que equilibra la precisión del entrenamiento con el tamaño del árbol [6]. Un árbol excesivamente grande (complejo) puede reducir el error en el entrenamiento a cero, pero fallará drásticamente en la generalización de datos no observados debido a la memorización del ruido estadístico [10]. La aplicación de este parámetro permite eliminar ramas que no aportan una ganancia significativa en la reducción de la impureza, transformando un árbol profundo en uno más compacto y estable [4, 17]. No obstante, en la arquitectura de Random Forest, la poda individual de los árboles suele ser innecesaria e incluso contraproducente, ya que la robustez del modelo final no depende de la estabilidad de un solo aprendiz, sino de la diversidad y el promediado de múltiples estimadores de alta varianza [6, 8].

$$R_\alpha(T) = R(T) + \alpha|T| \quad (6.3)$$

6.2.4. Inestabilidad Estructural y Análisis de Varianza

Los árboles de decisión únicos son estimadores de alta capacidad pero sufren de una inestabilidad estructural inmanente ante perturbaciones estocásticas en el conjunto de entrenamiento [9]. Debido a su naturaleza no paramétrica, variaciones mínimas en el dataset original pueden alterar el primer split en el nodo raíz, propagando cambios topológicos radicales a lo largo de toda la jerarquía del árbol [6, 11]. Esta sensibilidad implica que el error de predicción está dominado por la varianza del modelo, lo que degrada la fiabilidad en entornos reales complejos como el diagnóstico médico o la seguridad en redes [8, 14]. El análisis de varianza revela que los árboles profundos tienden a generar fronteras de decisión altamente irregulares que capturan las fluctuaciones del ruido en lugar de la función de densidad subyacente [10]. Esta fragilidad operativa motivó la transición hacia el aprendizaje de ensamble, donde se busca transformar múltiples aprendices débiles e inestables en un aprendiz fuerte y robusto [7, 9]. Random Forest resuelve este dilema mediante la descorrelación de los errores individuales, estabilizando el rendimiento general frente a datos ruidosos o desbalanceados [2, 18].

$$Err(x) = Bias^2 + Variance + IrreducibleError \quad (6.4)$$

6.2.5. Bootstrap Aggregating (Bagging) y Muestreo con Reemplazo

La técnica central que permite la estabilización de Random Forest es el Bootstrap Aggregating o Bagging [6, 7]. Este proceso estocástico genera B subconjuntos de entrenamiento distintos mediante el muestreo aleatorio con reemplazo del dataset original [8]. Matemáticamente, para un dataset de tamaño N , la probabilidad de que una observación específica no sea seleccionada en una muestra de bootstrap es aproximadamente $(1 - 1/N)^N$, lo cual converge a $e^{-1} \approx 0.368$ a medida que N tiende a infinito [16, 19]. Estas muestras "no elegidas", denominadas Out-Of-Bag (OOB), permiten al algoritmo validar cada árbol de forma interna y paralela [16]. Al entrenar cada árbol sobre una realización distinta del proceso de generación de datos, se reduce la varianza del ensamble sin incrementar el sesgo, ya que el promediado (en regresión) o la votación mayoritaria (en clasificación) diluye los errores aleatorios cometidos por los árboles individuales [6, 8, 20].

$$P(\text{no selección}) = \lim_{N \rightarrow \infty} \left(1 - \frac{1}{N}\right)^N = \frac{1}{e} \approx 0,368 \quad (6.5)$$

6.2.6. Selección Aleatoria de Subespacios de Características

Random Forest optimiza el paradigma del Bagging mediante la inyección de una segunda capa de aleatoriedad: el método de subespacios aleatorios [5,9]. En cada partición de cada nodo de cada árbol, el algoritmo no evalúa la totalidad de los p atributos disponibles, sino que restringe la búsqueda a un subconjunto aleatorio de tamaño m [6,21]. La regla convencional establece que $m = p$

para tareas de clasificación, lo que fuerza la diversidad estructural entre los estimadores del bosque [18,20]. Este mecanismo es fundamental para evitar que variables con un poder predictivo dominante capturen la estructura de todos los árboles del ensamble [9]. Sin esta restricción, un Bagging estándar produciría árboles altamente correlacionados entre sí, limitando la reducción de la varianza total [6]. Al seleccionar aleatoriamente las características, Random Forest asegura que incluso las variables menos informativas tengan la oportunidad de participar en la construcción de reglas, lo que resulta vital en problemas de alta dimensionalidad como la bioinformática y el análisis de señales IoT [21,22].

$$m = \lfloor \sqrt{p} \rfloor \quad \text{o} \quad m = \log_2(p) + 1 \quad (6.6)$$

6.2.7. Teorema de Convergencia de Breiman

Uno de los pilares matemáticos que garantiza la superioridad de Random Forest es el Teorema de Convergencia de Breiman, el cual demuestra que el bosque no sobreajusta a medida que el número de árboles B aumenta hacia el infinito [5,6]. A diferencia de otros métodos de ensamble que pueden volverse excesivamente complejos, Random Forest converge hacia un límite superior del error de generalización que depende exclusivamente de dos factores: la fuerza de los árboles individuales y la correlación media entre ellos [6,9]. La ley de los grandes números asegura que, tras un número suficiente de estimadores (generalmente entre 100 y 500 según la literatura), el error de generalización se estabiliza, transformando el modelo en un sistema de votación robusto [2,6,20]. Esta convergencia permite que RF maneje de forma intrínseca el ruido y los valores atípicos, superando la fragilidad de los árboles únicos que dependen de particiones específicas del dataset [8,10].

$$\lim_{B \rightarrow \infty} PE^* = P_{X,Y}(P_{\Theta}(h(X, \Theta) = Y) - \max_{j \neq Y} P_{\Theta}(h(X, \Theta) = j) < 0) \quad (6.7)$$

6.2.8. Función de Correlación entre Árboles (P)

La eficacia de Random Forest en la reducción de la varianza está inversamente relacionada con la correlación entre los árboles individuales [2,9]. Matemáticamente, la varianza de un ensamble de B árboles promediados se define por la ecuación de varianza de variables correlacionadas, donde un valor bajo de P es crítico para minimizar el error total [20]. Al aplicar el muestreo de bootstrap y la selección aleatoria de características, RF reduce sistemáticamente esta correlación, desacoplando las predicciones de los estimadores [9,13]. Si P es alto, el ensamble se comporta como un solo árbol, heredando todas sus inestabilidades [9]. Por el contrario, al inyectar aleatoriedad doble, Random Forest asegura que los árboles cometan errores en diferentes regiones del espacio de características, permitiendo que la votación colectiva cancele dichos errores y resalte la tendencia subyacente real [6–8]. Esta descorrelación es lo que permite que RF supere a los árboles de decisión en precisión y robustez operativa [10,11].

$$\text{Varianza}_{\text{Bosque}} = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2 \quad (6.8)$$

6.2.9. Estimación Analítica del Error Out-Of-Bag (OOB)

Una de las ventajas metodológicas más significativas de Random Forest es su capacidad de autovalidación mediante la estimación del error Out-Of-Bag (OOB) [16, 19]. Dado que cada observación se excluye del entrenamiento de aproximadamente un tercio de los árboles del bosque, el conjunto OOB actúa como un conjunto de prueba natural y permanente [16]. El error OOB se calcula evaluando cada instancia utilizando únicamente la sub-colección de árboles que no la vieron durante su fase de ajuste [16, 19]. Esta métrica proporciona una estimación insesgada del error de generalización, eliminando la necesidad de recurrir a esquemas externos de validación cruzada k-fold, lo que reduce drásticamente el costo computacional en grandes volúmenes de datos [16, 19]. La convergencia del error OOB a menudo refleja con alta fidelidad el comportamiento del modelo en producción, permitiendo la optimización de hiperparámetros como la profundidad máxima o el número de estimadores con una base científica sólida [16, 23].

$$OOBError = \frac{1}{N_{OOB}} \sum_{t=1}^T \sum_{x_i \in OOB_t} \mathbb{I}(\hat{y}_t(x_i) \neq y_i) \quad (6.9)$$

6.2.10. Fundamentos Matemáticos de la Importancia de Variables

Random Forest ofrece una capacidad intrínseca para cuantificar la relevancia de cada variable en el proceso de clasificación, una funcionalidad crítica para la explicabilidad del modelo [18, 23]. El Mean Decrease Impurity (MDI) calcula la importancia sumando la reducción total de la impureza de Gini o entropía que aporta una variable específica a través de todos los nodos donde fue seleccionada para un split [15, 18]. Esta métrica permite identificar biomarcadores clave en medicina o factores de riesgo críticos en finanzas [10, 22]. Complementariamente, la Importancia por Permutación evalúa el impacto de una variable midiendo cuánto aumenta el error OOB cuando los valores de dicha característica se permutan aleatoriamente, rompiendo su relación con la etiqueta de clase [7, 9, 18]. Estos fundamentos matemáticos transforman a Random Forest de una caja negra.^{en} una herramienta de diagnóstico estructural y analítico de alta precisión, superando la simple lógica de decisión de los árboles únicos [1, 2, 4].

$$VI(X_j) = \frac{1}{B} \sum_{b=1}^B \sum_{t \in \text{nodos}_b: v(t)=j} \Delta Gini(t) \quad (6.10)$$

6.3. Metodología y Análisis de la Literatura

El análisis sistemático de la literatura técnica contemporánea revela un consenso operativo sobre la superioridad de Random Forest (RF) en escenarios donde la varianza del Árbol de Decisión (DT) individual degrada la fiabilidad de la inferencia. Esta sección desglosa los hallazgos empíricos y metodológicos extraídos de un corpus de 30 investigaciones de alto impacto, categorizando el rendimiento algorítmico bajo diversas presiones de datos y requisitos de precisión.

6.3.1. Metodología de Revisión

La selección de los estudios analizados se rige por criterios de inclusión estenográficos centrados en la comparabilidad de arquitecturas de aprendizaje supervisado en el periodo 2021-2027 [1]. Se priorizaron investigaciones indexadas en bases de datos como IEEE Xplore, ScienceDirect y Scopus que proporcionaran métricas cuantitativas explícitas (Accuracy, AUC-ROC, F1-Score) y procesos de validación rigurosos como el muestreo de *bootstrap* o la validación cruzada k-fold [8, 17]. La metodología de síntesis agrupa los documentos según su dominio de aplicación, permitiendo evaluar cómo la inyección de aleatoriedad doble en RF mitiga el sesgo hacia la clase mayoritaria y la memorización del ruido estocástico [11].

6.3.2. Ciencias de la Salud

En el ámbito médico, la transición hacia modelos de ensamble responde a la necesidad de estabilidad diagnóstica frente a la alta dimensionalidad de los datos clínicos y genómicos. La detección de víctimas en entornos de desastre ha demostrado que, aunque el *Decision Tree* (específicamente J48) puede integrarse con características de *Deep Learning* para lograr precisiones del 99.53 por ciento, su sensibilidad a la segmentación visual requiere la robustez de modelos base descorrelacionados [3]. Por su parte, la predicción de demencia mediante una arquitectura híbrida que utiliza RF para la selección de características y GBDT para la predicción final alcanza una precisión de 0.96, validando que RF es capaz de filtrar atributos irrelevantes que suelen causar sobreajuste en árboles únicos [15]. El modelado del diagnóstico de diabetes mediante el sistema DHT (*Diabetes Health Tracer*) utiliza configuraciones de RF para optimizar la prognosis, superando significativamente a los modelos lineales y a los árboles simples [7]. En la evaluación exhaustiva de enfermedades cardíacas, RF alcanza una exactitud del 93.82 por ciento, posicionándose como una herramienta de soporte clínico fiable gracias a su capacidad de generalización en distintos particionamientos de datos [2]. Asimismo, en la clasificación de estados de colesterol basada en encuestas STEPS, RF se consolida como el mejor clasificador con un AUC de 96.17 por ciento [18]. La integración de lógica difusa (*fuzzy logic*) con ensambles de árboles para clasificar el COVID-19 refuerza que RF minimiza la incertidumbre subjetiva en el etiquetado de datos críticos [24]. Finalmente, en la clasificación de importancia de citas bibliográficas en medicina y ciencia, RF logra un AUC de 0.929, demostrando que la arquitectura de bosque es más resiliente a la dispersión léxica que un DT tradicional [13].

6.3.3. Riesgo Financiero y Economía

La volatilidad intrínseca de los datos económicos demanda modelos con una varianza mínima para evitar proyecciones erróneas. El análisis de insolvencia corporativa en la era del *Big Data* confirma que RF supera a los árboles individuales al capturar patrones no lineales en estados contables complejos, logrando un AUC de 0.99 tras aplicar técnicas de remuestreo [10]. En la identificación de riesgos financieros en tiempo real, sistemas basados en RF operan con umbrales dinámicos que superan la rigidez de las reglas de un árbol simple, alcanzando un F1-score de 0.8425 en alertas tempranas [16]. La literatura también explora la estimación de intervalos de confianza para puntuaciones de eficiencia operativa, donde RF desbanca al análisis envolvente de datos (DEA) tradicional al proporcionar estimaciones más robustas frente a *outliers* [6]. En ingeniería económica aplicada a materiales, la predicción de propiedades del concreto con caucho reciclado muestra que RF alcanza una correlación de $R=0.99$, validando su capacidad para modelar interacciones físicas complejas que un DT único fragmentaría excesivamente [19]. Incluso en la espectroscopía de ruptura inducida por láser (LIBS), RF mantiene errores medios absolutos inferiores a los estimadores base [25]. Finalmente, el análisis de válvulas hidráulicas proporcionales demuestra que la optimización de sistemas automatizados se beneficia de la estabilidad predictiva de RF para controlar transitorios dinámicos [26].

6.3.4. Ingeniería, IoT y Ciberseguridad

La resiliencia de Random Forest ante el ruido estocástico es fundamental en sistemas de monitoreo estructural y redes de sensores. En la detección de grietas en concreto, si bien el DT individual puede mostrar consistencia en muestras balanceadas con descriptores texturales definidos, RF compensa mejor las variaciones de iluminación y sombras en entornos urbanos no controlados [4]. El modelado de emisiones de CO₂ y N₂O a largo plazo utiliza RF optimizado para alcanzar un R^2 de 0.989, superando las limitaciones de los modelos lineales y los árboles simples en series temporales socioeconómicas [23]. La arquitectura de ensamble ha evolucionado hacia propuestas como el *Logically Randomized Forest* (LRF), que utiliza principios de teoría de grafos

para seleccionar subespacios de características, superando a RF y DT en datasets genómicos y de ingeniería [9]. En el campo educativo de la computación, RF es efectivo para clasificar estructuras de programas en CSE, superando la inestabilidad de clasificadores KNN en tareas simples [27]. En hidrología, RF supera a modelos ARIMA y árboles simples en la predicción estocástica de caudales diarios [5]. La bioinformática avanzada aplica RF para identificar firmas genéticas en el osteosarcoma, integrando el bosque en modelos diagnósticos de alta fidelidad [22]. En la gestión hospitalaria, RF predice el delirio post-quirúrgico y la duración de la estancia por tuberculosis, identificando factores críticos como la edad y la intervención farmacéutica [12, 28]. La aplicación de RF en la alfabetización de salud para pacientes con EPOC subraya su rol en la identificación de predictores cognitivos críticos [29]. En términos de privacidad, el uso de RF Federado permite entrenar modelos médicos sin compartir datos locales de los nodos, superando la precisión de los modelos locales individuales [14]. Para la seguridad IoT, la hibridación de RF con metaheurísticas de lobo gris logra una precisión del 99.96 por ciento contra intrusos [21]. Finalmente, en geología, RF se utiliza para separar áreas de anomalías geoquímicas en minería, superando la capacidad de clasificación del SVM y los árboles únicos [30].

6.3.5. Optimización Algorítmica

La optimización de RF reside en el ajuste fino de hiperparámetros que un árbol simple no posee, como el número de estimadores y el tamaño del subespacio aleatorio [1]. Comparativas exhaustivas indican que RF ofrece el mejor balance entre precisión operativa y robustez frente a otros modelos supervisados [17]. En entornos de redes imbalanceadas, RF es superior al DT para detectar ataques, capturando mejor la clase minoritaria mediante la agregación de perspectivas [11]. La evaluación de logs de servidores SIAKAD muestra que RF alcanza un 96.3 por ciento de exactitud, identificando anomalías con mayor precisión que los árboles individuales o el *Isolation Forest* [8]. En el rendimiento deportivo, RF minimiza el error en el modelado multimodal de atletas de remo [20]. El uso de búsqueda en cuadrícula (*Grid Search*) y optimizadores estocásticos consolida a RF como el estándar para mitigar el sobreajuste sin sacrificar la capacidad de representar interacciones no lineales de alta jerarquía [1, 28].

6.3.6. Mapeo Comparativo Macroscópico de la Literatura

Tabla 6.1: Análisis de Rendimiento: Árbol de Decisión vs. Random Forest

Dominio	Límite del Árbol	Solución de RF	Referencias Clave
Ciencias de la Salud	Inestabilidad en datos de alta dimensionalidad ($p \gg n$).	Selección de biomarcadores y reducción de varianza.	[2, 3, 7, 12–15, 18, 22, 24, 28, 29]
Finanzas y Economía	Fragmentación ante volatilidad y valores atípicos.	Estabilización robusta de intervalos de confianza.	[6, 10, 16, 19, 25, 26]
Ingeniería y Ciberseguridad	Sensibilidad extrema a ruido textural en sensores/logs.	Descorrelación de errores vía <i>bootstrapping</i> .	[4, 5, 8, 9, 21, 23, 27, 30]
Optimización	Rigidez inductiva en clases minoritarias.	Autovalidación insesgada mediante error OOB.	[1, 11, 17, 20]

El análisis sistemático de la literatura técnica contemporánea revela una trayectoria evolutiva donde la transición del particionamiento binario recursivo individual hacia arquitecturas de votación colectiva no constituye un cambio incremental, sino una respuesta estadística necesaria a la inestabilidad de los estimadores de alta capacidad [1, 2, 17]. La revisión de las 30 fuentes indexadas en este estudio permite mapear cómo las deficiencias estructurales de los árboles de decisión —específicamente su propensión al sobreajuste y la varianza extrema ante perturbaciones mínimas en el *training set*— se mitigan mediante la inyección de aleatoriedad doble y el promediado de aprendices descorrelacionados [6, 8, 9]. Este mapeo macroscópico categoriza los hallazgos empíricos según la naturaleza del dominio de aplicación y los requisitos de robustez operativa exigidos por la disciplina.

6.3.7. Síntesis de Limitaciones Estructurales Reportadas en la Literatura

La literatura técnica establece que la capacidad expresiva de un árbol de decisión individual, aunque óptima para la interpretabilidad mediante reglas condicionales directas, constituye su principal fragilidad estadística en problemas de clasificación del mundo real [1, 3]. Al ser estimadores no paramétricos de alta capacidad, los árboles tienden a generar fronteras de decisión ortogonales excesivamente complejas que memorizan el ruido estocástico del conjunto de entrenamiento en lugar de capturar la función de densidad subyacente [7, 9, 10]. Matemáticamente, esta inestabilidad implica que una variación infinitesimal en el dataset puede alterar la partición óptima del nodo raíz, propagando cambios topológicos radicales que derivan en una alta varianza del modelo [2, 4, 6]. Investigaciones aplicadas en bioinformática y detección de anomalías en redes confirman que los árboles únicos colapsan ante la presencia de características irrelevantes, fragmentando el espacio multidimensional en regiones que carecen de significancia estadística para datos no observados [8, 11, 21, 22].

La robustez geométrica de Random Forest surge de la descorrelación sistemática de estos estimadores inestables a través del mecanismo de aleatorización doble [5, 9]. El proceso de *Bootstrap Aggregating* garantiza que cada árbol se entrene en una realización distinta del proceso de generación de datos, donde la probabilidad de que una muestra no sea seleccionada se aproxima a $e^{-1} \approx 0,368$ [16, 19]. Esta técnica, combinada con la selección de subespacios aleatorios (típicamente $m = \sqrt{p}$ en clasificación), rompe la dependencia de los nodos respecto a variables dominantes que capturarían la estructura de un árbol simple [9, 13, 20]. El Teorema de Convergencia de Breiman, citado implícitamente en comparativas de rendimiento clínico y financiero, demuestra que a medida que el número de estimadores en el bosque aumenta, el error de generalización no diverge hacia el sobreajuste, sino que converge hacia un límite superior determinado por la fuerza de los árboles individuales y su baja correlación mutua [6, 14, 17, 23].

Finalmente, la literatura reporta que la ventaja competitiva de Random Forest sobre el árbol de decisión es especialmente crítica en entornos de clases desbalanceadas y alta dimensionalidad léxica o genética [7, 10, 13]. Mientras que el árbol individual suele sesgarse hacia la clase mayoritaria por la rigidez de su criterio de división (índice de Gini o Entropía), Random Forest permite capturar las reglas sutiles de la clase minoritaria mediante la agregación de perspectivas diversas proporcionadas por múltiples subconjuntos de datos [11, 15, 18, 24]. La capacidad de autovalidación mediante el error *Out-Of-Bag* (OOB) elimina la necesidad de esquemas externos de validación cruzada, permitiendo que modelos aplicados en IoT, salud federada o geología operen con una estimación insesgada de su precisión operativa [14, 16, 27, 30]. En síntesis, la transición hacia el bosque aleatorio representa el paso de una lógica de decisión única y frágil a una arquitectura de robustez colectiva capaz de manejar la incertidumbre inherente a los *datasets* modernos de alta complejidad [12, 25, 26, 28, 29].

Agrupación por Enfoques Metodológicos y Taxonomía de Datos

El análisis de la literatura revela una divergencia metodológica fundamentada en la naturaleza dimensional y estructural de los conjuntos de datos, donde la heterogeneidad de la información —estructurada, series temporales, registros de sensores y logs de red— determina la arquitectura óptima del clasificador. En el dominio de los datos estructurados aplicados a la salud y las finanzas, el diseño metodológico común se orienta a capturar interacciones no lineales que los modelos lineales y los árboles de decisión únicos fragmentan excesivamente [2, 7]. Investigaciones en el diagnóstico de diabetes y enfermedades cardíacas demuestran que, ante variables metabólicas y demográficas altamente correlacionadas, Random Forest (RF) actúa como un regulador de varianza, superando la rigidez inductiva de algoritmos como C4.5 o J48 [7, 18]. Esta capacidad de generalización es igualmente crítica en la predicción de insolvencia corporativa y riesgos financieros, donde la volatilidad de los indicadores contables introduce un ruido estocástico que los árboles únicos memorizan, derivando en un sobreajuste estructural que RF neutraliza mediante el promediado de estimadores descorrelacionados [10, 16]. En contextos de alta dimensionalidad genómica y bioinformática, la taxonomía de datos tipo pn (donde el número de características supera al de observaciones) exige un proceso de selección de subespacios aleatorios para evitar la "maldición de la dimensionalidad". El modelado de biomarcadores para el osteosarcoma valida que RF, al evaluar un subconjunto de genes en cada nodo, impide que un grupo pequeño de variables dominantes determine la topología de todo el bosque, permitiendo el descubrimiento de patrones latentes [22]. Evoluciones algorítmicas como el *Logically Randomized Forest* (LRF) refinan este enfoque mediante la manipulación lógica de los atributos de entrada, logrando precisiones superiores en datasets genómicos complejos al inyectar una aleatoriedad controlada que desacopla la correlación residual entre árboles [9]. El procesamiento de imágenes técnicas y médicas introduce un desafío adicional relacionado con el ruido textural y las sombras. En la detección de grietas en concreto o víctimas en entornos de desastre, el diseño experimental integra descriptores como HOG, LBP y GLCM, donde el árbol de decisión suele fallar por su sensibilidad a variaciones infinitesimales en el brillo o la textura [3, 4]. La literatura indica que RF compensa estas inconsistencias visuales mediante el *bagging*, estabilizando el rendimiento en condiciones operativas no controladas [4]. Asimismo, en aplicaciones de espectroscopía de ruptura inducida por láser (LIBS) y modelado de materiales como el concreto cauchutado, RF demuestra una robustez superior al manejar la alta variabilidad de las señales físicas, logrando coeficientes de correlación cercanos a la unidad que superan la capacidad predictiva de los modelos base [19, 25].

6.4. Conclusiones

- **Optimización del balance sesgo-varianza:** La principal ventaja estructural de Random Forest reside en su capacidad para mitigar la alta varianza intrínseca de los árboles de decisión individuales. Mientras que un modelo de árbol único tiende a memorizar el ruido estocástico del conjunto de entrenamiento (sobreajuste), el bosque aleatorio estabiliza el error de generalización mediante el promediado de múltiples estimadores descorrelacionados, garantizando una inferencia significativamente más fiable ante datos no observados.
- **Resiliencia ante perturbaciones estocásticas:** La implementación de una doble capa de aleatorización —Bootstrap Aggregating y selección aleatoria de atributos— dota al modelo de una robustez superior frente a valores atípicos y ruido textural. En dominios con alta variabilidad, como la captura de señales mediante sensores o el análisis de logs industriales, la votación colectiva neutraliza los errores aleatorios de los aprendices base, permitiendo capturar la función de densidad real de los datos.
- **Gestión eficiente de la maldición de la dimensionalidad:** En escenarios donde el número de variables supera ampliamente al de observaciones ($p \gg n$), los árboles indivi-

duales suelen generar topologías fragmentadas y poco profundas. Random Forest resuelve este desafío técnico al restringir la evaluación de características en cada nodo, lo que previene que variables dominantes enmascaren patrones informativos latentes y asegura una exploración exhaustiva del espacio de características.

- **Validación interna mediante el indicador Out-Of-Bag (OOB):** Metodológicamente, la arquitectura de bosque ofrece una ventaja competitiva mediante el uso del error OOB. Esta capacidad de autovalidación proporciona una estimación insesgada del rendimiento del clasificador sin requerir particiones adicionales del dataset o esquemas de validación cruzada externos, optimizando el aprovechamiento de los datos y reduciendo drásticamente la carga computacional en entornos de *Big Data*.
- **Resolución del compromiso entre transparencia y precisión:** Si bien se produce una pérdida de la interpretabilidad directa propia de la "caja blanca" de un árbol único, este sacrificio estadístico se justifica plenamente por el incremento en la exactitud y la estabilidad del modelo. La integración de técnicas modernas de importancia de variables y herramientas XAI permite recuperar la trazabilidad de las decisiones, consolidando al bosque aleatorio como el estándar para aplicaciones de alta responsabilidad en salud y finanzas.
- **Escalabilidad y versatilidad arquitectónica:** La naturaleza descentralizada de los ensambles arbóreos facilita su integración en paradigmas de vanguardia como el aprendizaje federado. Esto permite el despliegue de modelos de alta fidelidad en infraestructuras distribuidas, garantizando la privacidad de la información sensible y asegurando una convergencia global robusta, lo que posiciona a Random Forest como la base fundamental de los sistemas de inferencia autónomos contemporáneos.

Referencias

- [1] M. I. Khaldi, A. Erraissi, M. Hain, and M. Banane, “In-depth comparison of supervised classification models - performance and adaptability to practical requirements,” *International Journal of Advanced Computer Science and Applications*, vol. 16, no. 8, 2025.
- [2] M. E. Asgarabad, “Comprehensive evaluation of machine learning algorithms for heart disease prediction,” *Discover Artificial Intelligence*, vol. 6, no. 331, 2026.
- [3] G. Seeja, A. S. Arockia Doss, and V. B. Hency, “A novel approach for disaster victim detection under debris environments using decision tree algorithms with deep learning features,” *IEEE Access*, vol. 11, pp. 53134–53148, 2023.
- [4] A. F. C. Forero and S. A. C. Toro, “Evaluación de técnicas de preprocesamiento y clasificación automática (random forest y decisión tree) en imágenes digitales de fisuras y grietas en concreto,” informe final trabajo de grado, Unidades Tecnológicas de Santander, 2025.
- [5] K. Khosravi, A. Golkarian, M. J. Booij, R. Barzegar, W. Sun, Z. M. Yaseen, and A. Mosavi, “Improving daily stochastic streamflow prediction: comparison of novel hybrid data-mining algorithms,” *Hydrological Sciences Journal*, 2021.
- [6] J. Aparicio, V. Charles, and M. D. Guillen, “Estimating confidence intervals for efficiency scores via random forest,” *Omega*, vol. 143, p. 103585, 2026.
- [7] M. Noman, M. Hanif, A. Hameed, M. Babar, and B. Qureshi, “Machine learning-driven diabetes health tracer (dht): Optimizing prognosis using rask_grade and rask_gradel models,” *PLoS ONE*, vol. 20, no. 10, p. e0327661, 2025.
- [8] Ratih, A. H. P. Yuniarto, H. Ichwan, F. Mahardika, and R. Ripai, “Performance evaluation of random forest and isolation forest algorithms for detecting anomalies in siakad server log data,” *Sinkron: Jurnal dan Penelitian Teknik Informatika*, vol. 10, no. 2, 2026.
- [9] N. Jain and P. K. Jana, “Lrf: A logically randomized forest algorithm for classification and regression problems,” *Expert Systems with Applications*, vol. 213, p. 119225, 2023.
- [10] G. Gabrielli, A. Melioli, and F. Bertini, “Corporate financial distress prediction: a machine learning approach in the era of big data,” *Journal of Accounting & Organizational Change*, vol. 22, no. 7, 2025.
- [11] H. F. Soon, A. Amir, H. Nishizaki, N. A. H. Zahri, L. M. Kamarudin, and S. N. Azemi, “Evaluating tree-based ensemble strategies for imbalanced network attack classification,” *International Journal of Advanced Computer Science and Applications*, vol. 15, no. 1, 2024.
- [12] Ma and et al., “Construction of a predictive model for delirium in elderly patients after gynecological surgery using random forest,” *BMC Anesthesiology*, vol. 26, p. 97, 2026.
- [13] W. Bacha, A. Ashrafi, V. S. Mokhnachev, and A. Daud, “Machine learning techniques to identify the importance of data driven factors in citation classification,” in *Proceedings of 8th Computational Methods in Systems and Software (CoMeSySo 2024)*, pp. 1–16, 2025.

- [14] S. P. K. Veeranki, D. Hayn, D. Kramer, P. G. Gampawar, M. Baumgartner, L. D. Lorenzer, M. Schrempf, and G. Schreier, "Federated learning modelling methods applied for random forests for predicting delirium," *BMC Medical Informatics and Decision Making*, vol. 26, p. 41, 2026.
- [15] X. Ya, Y. Yan, and Zhou, "Dementia prediction based on random forest feature selection and gradient boosting decision tree," in *Proceedings of the 2023 6th International Conference on Artificial Intelligence and Pattern Recognition (AIPR)*, pp. 1–6, 2023.
- [16] B. Wang, "Financial risk identification and prevention system based on random forest algorithm," *Discover Artificial Intelligence*, vol. 6, no. 37, 2026.
- [17] M. I. Khaldi, A. Erraissi, M. Hain, and M. Banane, "In-depth comparison of supervised classification models - performance and adaptability to practical requirements," *International Journal of Advanced Computer Science and Applications*, vol. 16, no. 8, 2025.
- [18] F. G. Arage, T. G. Abate, T. K. Tsegaw, E. A. Alemu, Y. A. Tekle, M. B. Eyasu, and Z. B. Tadese, "Classification of current cholesterol status using ensemble-based machine learning," *Discover Artificial Intelligence*, vol. 6, no. 227, 2026.
- [19] M. Sheraz, M. Talha, M. Alam, M. Farhan, Z. U. Haq, M. Rashid, H. Alabduljabbar, and F. Ahmad, "Predicting mechanical properties of rubberized concrete using random forest," *Scientific Reports*, vol. 16, p. 40897, 2026.
- [20] Y. Wang and L. Liu, "Evaluation of random forest in rowing training performance modeling," *Discover Computing*, vol. 29, p. 182, 2026.
- [21] S. S. Alqahtany, A. Shaikh, and A. Alqazzaz, "Enhanced grey wolf optimization (egwo) and random forest based mechanism for iot security," *Scientific Reports*, vol. 16, p. 1916, 2026.
- [22] H. Zou and et al., "Integrated bioinformatics analysis and construction of a diagnostic model for osteosarcoma based on signature genes," *Discover Oncology*, vol. 17, p. 509, 2026.
- [23] Y. İdri m Özüpak and E. Aslan, "An enhanced interpretable ml approach for forecasting long-term co2 and n2o emissions via optimized random forest modeling," *Fuel*, vol. 427, p. 139723, 2027.
- [24] M. M. Salih, M. A. Ahmed, B. Al-Bander, K. F. Hasan, M. L. Shuwandy, and Z. T. Al-Qaysi, "Benchmarking framework for covid-19 classification machine learning method based on fuzzy decision by opinion score method," *Iraqi Journal of Science*, vol. 64, no. 2, pp. 922–943, 2023.
- [25] A. G. Capella, M. M. López, J. J. de Damborenea González, M. A. Arenas, and I. G. Diego, "Predictive performance of rf, gb and et in laser-induced breakdown spectroscopy," *Scientific Reports*, vol. 16, p. 46449, 2026.
- [26] M. Y. Salloom and M. Y. Almuhanha, "Analysis of the improved proportional hydraulic directional control valve by adding a solenoid directional valve," *Journal Européen des Systèmes Automatisés*, vol. 57, no. 1, pp. 105–115, 2024.
- [27] W. Crichton, G. G. Sampaio, and P. Hanrahan, "Automating program structure classification," in *Proceedings of the 52nd ACM Technical Symposium on Computer Science Education (SIGCSE '21)*, pp. 1–7, 2021.
- [28] Wang and et al., "Shortening hospital length of stay in tuberculosis patients through clinical pharmacist intervention based on machine learning," *BMC Infectious Diseases*, vol. 26, p. 110, 2026.

- [29] Wu and et al., “Machine learning to identify predictors of health information literacy in copd patients,” *BMC Pulmonary Medicine*, vol. 26, p. 190, 2026.
- [30] H. Mahdiyanfar, “Separating geochemical anomalies areas using machine learning in northern dalli, iran,” *Scientific Reports*, vol. 16, 2026.